

S30 - Entrega 2: Preparación e Ingesta de Datos mediante Web Scraping (EA2)

Estudiante: Yonier Alexis Quiceno Rodríguez

Universidad: IU Digital de Antioquia

Programa: Ingeniería de Software y Datos

Grupo: PREICA2601B020089 - Programación para Análisis de Datos

Docente: Ana Maria Lopez

Fecha: 31 de mayo de 2026

1. Alineación y Actualización de la Necesidad (Fase 1: Comprensión del Negocio)

1.1 Contexto e Integración del Proyecto

En la primera entrega (EA1), se definió y estructuró la base de datos transaccional local SQLite (`shopanalytics.db`) para la optimización del inventario físico de ShopAnalytics S.A.S. (control de sobrestock, alerta preventiva de reabastecimiento e indicadores regionales de disponibilidad) utilizando más de 5,000 registros transaccionales simulados.

Sin embargo, para lograr un **Sistema de Inteligencia de Mercado** verdaderamente proactivo, ShopAnalytics S.A.S. requiere cruzar su flujo transaccional con **factores macroambientales externos** (riesgos logísticos, políticos, cambiarios o huelgas en Latinoamérica) que impactan directamente los tiempos de importación, despacho y la

2. Comprensión y Preparación de los Datos (Fases 2 y 3 CRISP-DM)

2.1 Selección y Justificación Técnica de la Herramienta

Se evaluaron tres tecnologías líderes para la recolección de datos: **Scrapy**, **Selenium** y **BeautifulSoup**. La herramienta seleccionada fue **BeautifulSoup4 (BS4)** junto a la librería de peticiones **HTTP Requests**.

Cuadro Comparativo de Viabilidad Técnica

Herramienta	Consumo de CPU/RAM	Complejidad de Implementación	Idoneidad para BBC Mundo	Deci
	Muy Alto (Lanza navegador		Excesivo. BBC Mundo entrega su	

3. Diseño y Arquitectura de la Clase Scraper (POO en Python)

En cumplimiento con los estrictos criterios de la rúbrica de evaluación, el scraper está diseñado en su totalidad bajo el paradigma de **Programación Orientada a Objetos (POO)** en el archivo `src/scraper.py`, encapsulado en la clase `BBCMundoScraperP00`.

3.1 Estructura de la Clase `BBCMundoScraperP00`

```
classDiagram
    class BBCMundoScraperP00 {
        +string base_url
        +string topic_url
        +dict headers
        +string db_url
        +create_engine engine
        +__init__()
        +obtener_sopa(url) BeautifulSoup
```

4. Modelado e Ingesta de Datos (Fase 4 CRISP-DM)

4.1 Base de Datos Relacional PostgreSQL

Los datos del scraper se almacenan en una base de datos relacional PostgreSQL corporativa, ideal para la integración en Power BI y el procesamiento del modelo SVM de Machine Learning.

Estructura Física de la Tabla `noticias_mercado`

Campo SQL	Tipo de Datos	Restricción / Propósito
<code>id</code>	SERIAL	Primary Key (Autoincremental).
<code>titulo</code>	VARCHAR(255)	Título de la noticia.
<code>descripcion</code>	TEXT	Resumen corto del contenido.
<code>fecha_publicacion</code>	VARCHAR(50)	Metadata temporal de la noticia.

5. Evidencias de Ejecución y Pruebas de Validación

El script se ejecutó exitosamente en el entorno del proyecto. A continuación se presentan las evidencias directas del log de consola del scraper:

5.1 Registro de Ejecución del Pipeline ETL

```
=====
INICIANDO PIPELINE DE SCRAPING - SHOPANALYTICS S.A.S.
=====
[*] Escaneando listado de noticias en: https://www.bbc.com/mundo/topics/c7zp57yyz25t
[*] Se encontraron 48 tarjetas de noticias.

[*] Extrayendo detalle de artículos (Preparación para modelo SVM)...
  [1/24] Procesando: Muere el líder indígena Brooklyn Rivera ...
  [2/24] Procesando: Quiénes son los principales candidatos p...
  ...
  [24/24] Procesando: Raúl Castro, el último gran símbolo de l...

[*] Conectando a PostgreSQL para ingesta de datos...
```

6. Manejo de Excepciones y Robustez

El scraper cuenta con salvaguardas avanzadas para mitigar fallos durante ejecuciones prolongadas:

- **Falta de Texto en Artículos (Páginas de Video/Galerías):** Si un artículo carece del componente estándar `data-component="text-block"`, el scraper cuenta con un fallback dinámico que busca la etiqueta `<main>` o `<article>`, evitando la generación de valores nulos o detenciones abruptas del script.
- **Evasión de Bloqueos por Tráfico (Rate Limiting):** Implementación de una **Pausa Ética** de `1.5 segundos` entre peticiones, emulando la velocidad de navegación humana y reduciendo el riesgo de bloqueo de la dirección IP de origen.
- **Control de Excepciones en Base de Datos:** Si ocurre un fallo en la conexión con PostgreSQL (ej. caída del servidor cloud), se captura el error y se imprime por consola de forma segura sin abortar catastróficamente otros procesos encolados